


Data Analytics

Mini-Projekt

Prof. Dr. Jil Klünder

Ziel des Mini-Projekts

Ziel des Miniprojekts ist, dass ihr im Team (4-5 Personen) ein Datenanalyseprojekt mit den in der Vorlesung besprochenen Phasen durchführt und dokumentiert



Aufgabenstellung

Ihr sollt euch mit einem kompletten Datenanalyseprojekt beschäftigen.

Dokumentiert dazu jeden Schritt:

- Bereitet eine Powerpoint-Präsentation vor, um eure Ergebnisse und Erkenntnisse zu präsentieren
- Verfasst ein maximal 10-seitiges Dokument, in dem ihr die Schritte im Detail beschreibt und begründet. Das Dokument muss eure Fragestellung erläutern und motivieren, euer Vorgehen beschreiben und die Ergebnisse (zzgl. gewonnener Erkenntnisse und ableitbarer Handlungsempfehlungen) präsentieren. Ihr könnt euch dabei an Forschungspapieren orientieren.

Phase 1: Definition der Fragestellung

1. Findet und verfeinert eine Fragestellung, die ihr datengetrieben untersuchen möchtet.
 1. Stellt dar, wie ihr eine grobe Fragestellung zu einer oder mehreren konkreten Fragestellungen verfeinert, mit deren Hilfe ihr die grobe Fragestellung beantworten möchtet
 2. Stellt die Verfeinerung wie in der Vorlesung gezeigt grafisch dar oder nutzt eine andere Visualisierung
2. In der Dokumentation entspricht die Definition der Fragestellung der Einleitung.
 1. Führt zu eurer Fragestellung hin. Setzt sie dazu in einen größeren Kontext.
 2. Verdeutlicht eure (oder besser eine allgemeine) Motivation. Warum ist die Beantwortung eurer Fragestellung auch für andere interessant?

Tipps


- Sucht nach interessanten Fragestellungen!
 - Startet mit den Fragen, nicht mit zur Verfügung stehenden Daten
 - Messt, was ihr messen wollt; nicht alles, was ihr messen könnt
- Begründet die Relevanz der Fragestellung!
 - Paraphrasiert, was ihr (und andere) davon habt, wenn die Antwort auf eure Fragestellung bekannt ist

Phase 2: Planung des Vorgehens

1. Plant euer Vorgehen:
 1. Welche Tätigkeiten fallen an?
 2. Welche Daten braucht ihr? Müsst ihr Daten erheben?
 3. Erstellt einen groben Projektplan graphisch als Gantt-Chart.
2. In der Dokumentation passiert diese Phase „hinter den Kulissen“. Sie wird in der Dokumentation nicht explizit genannt.
 1. Schickt mir euer Gantt-Chart zu, sobald ihr es erstellt habt, und vereinbart einen individuellen Gesprächstermin mit mir, in dem wir über eure Projektplanung sprechen. Dieser Termin ist verpflichtend!

Gantt-Chart

- Ein Gantt-Chart ist ein horizontales Balkendiagramm, welches den Zeitplan eines Projekts und die Dauer einzelner Aufgaben sowie ihre Start- und Enddaten visualisiert
 - Es kann Abhängigkeiten zwischen Aufgaben und den Projektfortschritt darstellen
- Gantt-Charts helfen bei der Planung und Überwachung von Projektaufgaben, der Identifizierung von Engpässen im Projektverlauf



Excel-Templates für Gantt-Charts

<https://create.microsoft.com/en-us/templates/gantt-charts>

Phase 3: Datenbeschaffung

1. Sammelt die Daten, die ihr benötigt
 1. Identifiziert Datenquellen
 1. zum Beispiel aus dem Internet (kaggle, Statistik-Ämter, Wikipedia, Google, Twitter, GitHub, ...)
 2. Erhebt selbständig Daten, z.B. durch eine Umfrage unter Kommilitonen
2. In der Dokumentation habt ihr im Kapitel zur Methodik ein Unterkapitel zur Datensammlung oder zur Datenbasis, in dem ihr entweder den existierenden Datensatz im Detail beschreibt (im Idealfall auch, woher die Daten kommen) oder wie ihr die Daten erhoben habt (Struktur der Umfrage, Teilnehmerakquise, ...)

Phasen 4 – 5: Datenverarbeitung und -analyse

1. Verarbeitet und analysiert eure Daten
 1. Überlegt euch, wie ihr die Daten vorverarbeiten müsst
 2. Plant die Datenanalyse
2. In der Dokumentation gibt es ein Unterkapitel „Datenanalyse“
 1. Das füllt ihr mit den Unterkapiteln „Datenbereinigung und –vorverarbeitung“ und „Datenanalyse“

Phase 6: Dokumentation

1. Verfasst einen 10-seitigen Bericht über euer Datenanalyseprojekt
 1. Orientiert euch an den Informationen zur Dokumentation auf den vorigen Folien und aus der Vorlesung
 2. Ihr könnt euch auch an wissenschaftlichen Publikationen orientieren

Tipps für das Miniprojekt (und darüber hinaus) - 1

- **Stellt sicher, dass ihr die Analysen durchführen dürft!**
 - Nahezu kein Test und keine Analysemethode sind uneingeschränkt anwendbar
 - Daher müssen sämtliche Vorbedingungen überprüft werden (z.B. durch Überprüfung auf Normalverteilung)
 - Für nicht-triviale Fälle muss das auch dokumentiert werden
- **Paraphrasiert die Ergebnisse der Analysen**
 - Was bedeuten die Testergebnisse jenseits der Zahlen?
 - Formulieren von Erkenntnissen (Findings) kann helfen

Tipps für das Miniprojekt (und darüber hinaus) - 2

- Die Schlussfolgerungen müssen präzise und korrekt sein...
 - Die Überinterpretation der Ergebnisse passiert schneller, als man denkt, z.B. Korrelation vs. Kausalität
 - Fehlinterpretationen sind seltener (da oft offensichtlicher)
- Sichert die analytische Statistik mit einer deskriptiven Statistik ab...
 - Geht nicht blind in eine analytische Statistik – macht eine „Vorstudie“ mit deskriptiver Statistik – diese gibt euch ein Gefühl dafür, ob „irgendetwas schief“ ist, z.B. Verteilung...
 - Vertraut weder der einen, noch der anderen Statistik!

Tipps für das Miniprojekt (und darüber hinaus) - 3

- Bei der Dokumentation muss der Detailgrad stimmen...
 - Genug Details, um zu beurteilen, ob die Verfahren richtig angewendet wurden
 - Es muss auch einem unerfahrenen Leser klar sein, ob die Ergebnisse belastbar sind
 - Zu viele Details verwirren und unstrukturierte Details verwirren noch mehr
- Die Präsentation ist wichtig...
 - Die Ergebnisse sollten mit allen relevanten Werten präsentiert werden (nicht nur, ob das Ergebnis signifikant ist oder nicht)
 - Es gibt Richtlinien zur Präsentation der Ergebnisse. Die sollten berücksichtigt werden!
 - Klare Aussagen sind wichtig. Was sehen wir in den Daten? Und was nicht?

Tipps für das Miniprojekt (und darüber hinaus) - 4

- Hochkomplexe Statistik ist nicht immer besser...
 - In den meisten Fällen kommen wir mit den gängigen Tests oder Analysen aus
 - Je verschachtelter es wird, desto fehleranfälliger sind die Berechnungen
 - Komplexe Verfahren machen misstrauisch und können nicht ad hoc verstanden werden
 - Ergebnissen, die Leser nicht verstehen, vertrauen sie nicht (sehr überspitzt gesagt)

Mit komplexer Statistik beeindruckt ihr niemanden! Vielmehr besteht das Risiko, dass ihr am Ende eure eigene Arbeit nicht mehr versteht...

Präsentationen

- Die Präsentationen finden am 18.05., am 19.05. und am 26.05. statt
- Die Präsentationen sollen jeweils 20 Minuten lang sein.
- Erzählt die „Geschichte“ hinter eurer Analyse:
 - Wie seid ihr auf die Fragestellung gekommen?
 - Wie habt ihr die Daten erhoben und analysiert?
 - Was sind die Ergebnisse?
 - Was lest ihr daraus?
 - Was habt ihr gelernt?
- Ihr müsst Schwerpunkte für den Vortrag setzen. Überlegt euch, was ihr euren Kommilitoninnen und Kommilitonen mitgeben möchtet.

Abgaben

- Die Abgabe erfolgt über den Teams-Ordner „Abgaben“.
- Die Abgabe von den Präsentationsfolien und der schriftlichen Ausarbeitung muss bis zum 17.05. um 23:59 erfolgen.

Selbstständigkeitserklärung

Die Abgaben müssen eine Selbstständigkeitserklärung enthalten:

„Hiermit versichern wir, dass wir den Projektbericht „Miniprojekt Teil 1, Dokumentation der Phasen 1-3“ selbstständig verfasst und keine anderen als die angegebenen Quellen verwendet haben. Alle Textstellen und andere Inhalte wie Bilder, Quellcode oder Daten, die direkt, wörtlich oder sinngemäß aus anderen Quellen entnommen sind, haben wir eindeutig mit korrekten Quellenangaben versehen.“

Anwesenheitspflicht bei Miniprojekt-Präsentationen

- Bei den Miniprojekt-Präsentationen besteht grundsätzlich Anwesenheitspflicht (auch für die nicht vortragenden Gruppen)
- Meldet euch bei Bedarf bitte vorher per Email (gesendet von der FHDW-Emailadresse) bei mir ab