

# Speedrunning-Weltrekord-Analyse

Speedrunning World Record Analysis

## Projektarbeit

von

Mattis Dennhardt, Arun Dylan Gopala, Alex  
Haase,  
Viktor Lind, Darko Marjanovic, Benedikt Racette

Hannover, 17. Mai 2026

# Erklärung der Selbstständigkeit

Hiermit versichere ich, dass ich die vorliegende Projektarbeit selbstständig verfasst und keine anderen als die angegebenen Quellen verwendet habe. Alle Textstellen und andere Inhalte wie Bilder, Quellcode oder Daten, die wörtlich oder sinngemäß aus anderen Quellen entnommen sind, habe ich eindeutig mit korrekten Quellenangaben versehen. Über Zitierrichtlinien bin ich schriftlich informiert worden. Diese Arbeit wurde bisher in gleicher oder ähnlicher Form, auch nicht in Teilen, keiner anderen Prüfungsbehörde vorgelegt.

Hannover, den 17. Mai 2026

---

Mattis Dennhardt, Arun Dylan Gopala, Alex Haase,  
Viktor Lind, Darko Marjanovic, Benedikt Racette

# Zusammenfassung

Diese Ausarbeitung untersucht den Verlauf von Speedrunning-Weltrekorden auf der Plattform *speedrun.com*. Auf Basis von 842 Weltrekord-Datenpunkten aus 17 Spielen in sieben Genres werden drei Forschungsfragen beantwortet: (1) Wie stark hat sich die Bestzeit prozentual je Spielkategorie reduziert? (2) Gibt es einen Sättigungspunkt, ab dem weitere Verbesserungen abnehmen? (3) Welchen Einfluss haben externe Beschleuniger auf die Rekordentwicklung — konkret: setzt ein Durchbruch die Abflachungsrate zurück (3a), ist der Tool-Einfluss im Datensatz messbar (3b), und wie lange hält ein Weltrekord im Mittel je Genre und Jahrzehnt (3c)?

Als Methoden kommen nichtparametrische Tests (Kruskal-Wallis, Mann-Whitney U), der Kaplan-Meier-Schätzer für Überlebenszeitanalysen sowie AIC-basierter Modellvergleich mit anschließendem Chow-Test auf Strukturbrüche zum Einsatz.

Die Ergebnisse zeigen erhebliche Unterschiede in der Zeitreduktion zwischen Spielen (**9,4 % bis 99,5 %**). Verbesserungsdynamiken weisen universelle Strukturbrüche auf (Chow-Test, **alle 17 Spiele** signifikant), was auf initiale Optimierungsschübe durch frühe Community-Aktivität hindeutet. Nach einem Durchbruch-Ereignis zeigen **5 von 6** auswertbaren Spielen ein klares Plateau ( $\phi < 0,5$ ); Durchbrüche setzen die Abflachungsrate demnach nicht zurück, sondern leiten eine Konsolidierungsphase ein. Für **2 von 17 Spielen** ist ein stabiler Modell-Grenzwert bestimmbar: *Half-Life 2* hat **95,5 %** der möglichen Reduktion bis zum Modell-Floor erreicht, *Pokémon Red/Blue* **82,5 %**. Die Lebensdauer von Weltrekorden unterscheidet sich signifikant zwischen Genres (**H(6) = 43,82; p < 0,001;  $\eta^2 \approx 0,044$** ), wobei RPG-Rekorde mit einem Kaplan-Meier-Median von **52 Tagen** deutlich länger Bestand haben als Rekorde anderer Genres (Median: **7–17 Tage**).

# Inhaltsverzeichnis

|          |                                                            |           |
|----------|------------------------------------------------------------|-----------|
| <b>1</b> | <b>Einleitung</b>                                          | <b>1</b>  |
| <b>2</b> | <b>Datenbasis und Methodik</b>                             | <b>4</b>  |
| 2.1      | Datenbeschaffung und Aufbereitung . . . . .                | 4         |
| 2.2      | Statistische Methoden . . . . .                            | 4         |
| <b>3</b> | <b>Ergebnisse</b>                                          | <b>8</b>  |
| 3.1      | F1 — Prozentuale Zeitreduktion . . . . .                   | 8         |
| 3.2      | F2 — Sättigung der Verbesserungsrate . . . . .             | 9         |
| 3.3      | F3 — Externer Einfluss auf die Rekordentwicklung . . . . . | 10        |
| <b>4</b> | <b>Diskussion</b>                                          | <b>13</b> |
| 4.1      | Interpretation der Ergebnisse . . . . .                    | 13        |
| 4.2      | Limitationen . . . . .                                     | 15        |
| <b>5</b> | <b>Fazit</b>                                               | <b>17</b> |

# Kapitel 1

## Einleitung

Speedrunning bezeichnet die Praxis, Videospiele so schnell wie möglich abzuschließen. Was ursprünglich als Nischenbeschäftigung begann, hat sich zu einer globalen Wettbewerbskultur mit eigenen Events, Kommentatoren und einer kontinuierlich wachsenden Online-Community entwickelt. Die Plattform *speedrun.com* dient als zentrale Anlaufstelle: Sie sammelt, verifiziert und archiviert Weltrekordversuche aus tausenden von Spielen und stellt die historischen Daten über eine öffentliche API bereit [spe24a].

Für eine Datenanalyse eignen sich Speedrunning-Weltrekorde besonders gut. Alle Laufzeiten werden in Sekunden gemessen und von der Community verifiziert; der Beobachtungszeitraum reicht bei einigen Spielen bis in die 1990er Jahre zurück. Die Daten sind nach Genre und Kategorie gegliedert und erlauben Vergleiche zwischen verschiedenen Spielgruppen. Weltrekorde sind dabei ein kollektiver Optimierungsprozess: Eine dezentrale Community entdeckt schrittweise neue Routen, Bewegungstechniken und Programmfehler (sogenannte *Glitches*), die kürzere Durchläufe ermöglichen. Erste wissenschaftliche Analysen zeigen, dass Weltrekordverbesserungen Potenzgesetz-Mustern folgen und systematische Trendbrüche aufweisen [ES23].

## Forschungsfragen

Diese Ausarbeitung untersucht anhand eines selbst erhobenen Datensatzes aus 17 Spielen in sieben Genres drei Forschungsfragen:

1. **Zeitreduktion:** Wie stark hat sich die Bestzeit prozentual je Spielkategorie reduziert, und unterscheiden sich Genres systematisch in ihren Verbesserungsraten?
2. **Sättigung:** Folgt die Verbesserungsrate einem erkennbaren mathematischen Muster, und gibt es einen statistisch nachweisbaren Sättigungspunkt?

3. **Externer Einfluss:** Welchen Einfluss haben externe Beschleuniger auf die Rekordentwicklung?
- 3a. Setzt ein bekannter Durchbruch (Glitch-Entdeckung, neues Routing) die Abflachungsrate zurück?
  - 3b. Ist der Einfluss von Tools und Glitches im Datensatz statistisch nachweisbar?
  - 3c. Wie lange hält ein Weltrekord im Mittel, differenziert nach Genre und Jahrzehnt?

Abbildung 1.1 zeigt den KAOS-Baum,<sup>1</sup> der die Beziehungen zwischen den Forschungsfragen, dem Datensatz und dem Analyseziel darstellt.




Abbildung 1.1: KAOS-Baum der Speedrunning-Weltrekordanalyse

## Zielsetzung und wissenschaftlicher Beitrag

Bisherige Arbeiten beschreiben Speedrunning-Weltrekordkurven auf einer übergeordneten Ebene [ES23], beantworten aber nicht, welche Mechanismen einzelne Sprünge in einer Rekordreihe erklären und wie nah menschliche Rekorde dem theoretischen Minimum kommen. Diese Arbeit untersucht genau das: Sie misst erstmals die *Post-Breakthrough-Dynamik* (F3a) — die Veränderung der Verbesserungsrate nach einem Schlüsselereignis — und die Annäherung ans theoretische Minimum (F3b) für 17 Spiele. Die wesentlichen Beiträge sind: (1) nachprüfbare Ergebnisse für beide Effekte auf Basis öffentlicher Daten, (2) Genrevergleich für F1 und F3c, (3) Modellvergleich über fünf Kurventypen für F2.

Die Ausarbeitung beschreibt zunächst Datenbasis und Methodik (Kap. 2), präsentiert die Ergebnisse zu allen drei Forschungsfragen (Kap. 3), diskutiert

<sup>1</sup>KAOS: Konzepte, Annahmen, Operationen, Struktur — ein Modell zur Strukturierung von Forschungsfragen.

Ergebnisse und Einschränkungen (Kap. 4) und schließt mit einem Fazit (Kap. 5).

## Kapitel 2

# Datenbasis und Methodik

### 2.1 Datenbeschaffung und Aufbereitung

Die Rohdaten wurden über die *speedrun.com* API v1 [spe24a] abgerufen. Ausgewählt wurden 17 Spiele aus sieben Genres: Platformer (Super Mario Bros., Super Mario 64, Celeste), Action-Adventure (Super Metroid, Zelda: Ocarina of Time, Hollow Knight), RPG (Pokémon Red/Blue, Final Fantasy VII), FPS (Doom 3, Quake, Half-Life 2), Puzzle (Portal, Portal 2, The Talos Principle), Sandbox (Minecraft: Java Edition) und Arcade (Pac-Man, Donkey Konga). Alle Analysen beschränken sich auf die *any%*-Kategorie,<sup>1</sup> da diese als einzige Kategorie in allen 17 Spielen vorhanden und vergleichbar ist.

Der Datensatz umfasst insgesamt 77.686 eingereichte Runs und 842 Weltrekord-Einträge aus 17 Spielen. Im Bereinigungsschritt wurden offensichtlich fehlerhafte WR-Einträge entfernt: Weltrekordzeiten unter 1 % des Medians der jeweiligen WR-Progression und unter 1,0 Sekunde gelten als Fehler (z. B. Moderator-Platzhalter oder Tippfehler) und werden verworfen — beschränkt auf Spiele mit Median > 10 Sekunden, damit Arcade-Spiele mit legitim kurzen Zeiten unberührt bleiben. Die bereinigten Daten werden in fünf CSV-Dateien exportiert; eine konsistente Dezimaldarstellung aller Float-Spalten stellt ein Normalisierungsmodul (`shared/utis.py`) sicher.

### 2.2 Statistische Methoden

#### F1 — Prozentuale Zeitreduktion (Q1)

Die prozentuale Zeitreduktion je Spiel  $i$  berechnet sich als  $r_i = (t_{\text{first},i} - t_{\text{best},i}) / t_{\text{first},i} \cdot 100\%$ , wobei  $t_{\text{first},i}$  die erste und  $t_{\text{best},i}$  die aktuell beste Laufzeit

---

<sup>1</sup>Any% bezeichnet in der Speedrunning-Community den schnellsten Weg zum Spielabschluss, unabhängig vom Fertigstellungsgrad.

im Datensatz ist. Zusätzlich werden die jährliche Verbesserungsrate und die Weltrekord-Dichte berechnet.

Um zu prüfen, ob Genres sich systematisch in ihren jährlichen Raten unterscheiden, wird der **Kruskal-Wallis-Test** [Kim16] eingesetzt. Dieser nichtparametrische Test arbeitet mit Rangzahlen statt Rohdaten und setzt keine Normalverteilung voraus — eine wichtige Eigenschaft, da Laufzeit-Daten typischerweise stark rechtsschief verteilt sind.

## F2 — Sättigung der Verbesserungsrate (Q2)

Für jedes Spiel wird die kumulierte Bestzeit gegen den Weltrekord-Index aufgetragen. Anschließend werden fünf Kurvenmodelle mittels nichtlinearer Regression angepasst: logarithmisch, quadratisches Polynom (poly2), exponentieller Zerfall, Gompertz-Kurve und LOWESS (nichtparametrisch). Der Modellvergleich erfolgt über das **Akaike-Informationskriterium** (AIC) [DTY18]: Ein niedrigeres AIC zeigt ein besseres Verhältnis von Anpassungsgüte zu Modellkomplexität an — komplexere Modelle werden also nur bevorzugt, wenn sie die Daten deutlich besser erklären. Das Modell mit dem niedrigsten AIC je Spiel gilt als bestes Modell.

Um den Sättigungspunkt direkt nachzuweisen, wird der **Chow-Test** [ZLHK02] eingesetzt. Dieser prüft, ob sich die Regressionskoeffizienten vor und nach einem möglichen Strukturbruch signifikant unterscheiden ( $F$ -Statistik gegen  $F$ -Verteilung). Alle validen Trennpunkte werden durchsucht; der Trennpunkt mit der höchsten  $F$ -Statistik wird als Strukturbruch gemeldet. Der Test setzt voraus, dass die Residuen innerhalb beider Segmente annähernd gleich gestreut sind (Homoskedastizität). Da WR-Zeitreihen mit zunehmender Sättigung stabiler werden, ist diese Voraussetzung im Post-Break-Segment in der Regel besser erfüllt als im gesamten Verlauf; die Ergebnisse sind entsprechend konservativ zu interpretieren.

## F3a — Post-Breakthrough-Dynamik

Um zu untersuchen, ob ein identifizierbares Durchbruchereignis die Verbesserungsrate zurücksetzt oder abflacht, wird für jedes Spiel der **Breakthrough** als derjenige WR definiert, bei dem die absolute Zeitersparnis gegenüber dem Vorgänger-Weltrekord am größten ist — meistens eine Glitch-Entdeckung oder ein großes Routing-Update.

Die WR-Zeitreihe wird am Breakthrough-Punkt in zwei Segmente geteilt, für die jeweils die **Verbesserungsgeschwindigkeit** (Velocity) berechnet

wird:

$$v_{\text{pre}} = \frac{\sum \Delta t_{\text{pre}}}{d_{\text{pre}}} \quad [\text{s/Tag}]$$

$$v_{\text{post}} = \frac{\sum \Delta t_{\text{post}}}{d_{\text{post}}} \quad [\text{s/Tag}]$$

Das **Flattening Ratio**  $\phi = v_{\text{post}}/v_{\text{pre}}$  quantifiziert die Veränderung:  $\phi < 0,5$  signalisiert ein klares Plateau,  $\phi > 1,0$  eine Beschleunigung,  $0,5 \leq \phi \leq 1,0$  eine graduelle Verlangsamung. Ein ergänzender **Spearman-Rangkorrelationstest** ( $\rho$ ) quantifiziert den zeitlichen Trend der Post-Breakthrough-Verbesserungsgrößen ( $\rho < -0,2$ : abnehmend,  $\rho > 0,2$ : zunehmend).

Ursprünglich war eine Regression des Abfall-Koeffizienten je Segment geplant. Da viele Segmente jedoch zu wenige Datenpunkte für eine stabile Kurvenanpassung enthalten, wurde der Velocity-Ansatz als robustere Alternative gewählt.

Diese Methode unterscheidet sich vom Chow-Test aus F2: Während der Chow-Test den stärksten Steigungswechsel in der kumulierten Kurve markiert, identifiziert der hier gewählte Ansatz den größten *einzelnen* Verbesserungsschritt — eine direktere Entsprechung für Glitch-Entdeckungen.

### F3b — Annäherung ans theoretische Minimum

Das theoretische Zeitminimum einer Speedrunning-Kategorie entspricht dem, was unter optimaler, computergestützter Eingabe möglich wäre — sogenannte Tool-Assisted Speedruns (TAS). Ein direkter Vergleich mit TAS-Zeiten war im Rahmen dieser Arbeit nicht durchführbar: *speedrun.com* untersagt TAS-Einreichungen auf regulären Leaderboards [spe24b], verlässliche TAS-Zeiten sind über keine öffentliche API verfügbar, und die vorhandenen TAS-Videos erfordern eine Frame-genaue Auswertung des tatsächlichen Startzeitpunkts — ein Aufwand, der im gegebenen Zeitrahmen nicht leistbar war. Als Näherung wird stattdessen der mathematische Grenzwert der Sättigungskurve verwendet:

**Modellbasierter Asymptoten-Proxy.** Für alle 17 Spiele wird der Floor-Parameter des besten Sättigungsmodells (*exp\_decay* oder *Gompertz*,  $R^2 \geq 0,70$ ) als Schätzwert für das theoretische Minimum genutzt:

$$\text{Gap}_{\%} = \frac{t_{\text{WR}} - t_{\text{Floor}}}{t_{\text{first}}} \times 100$$

### Qualitätssicherung

Die vollständige Analysepipeline ist durch **164 automatisierte pytest-Tests** abgedeckt, die mit synthetischen In-Memory-Daten arbeiten und

keine externen Datendateien benötigen. Geprüft werden: Kurvenanpassung (logarithmisch, poly2, exp\_decay, Gompertz, Potenzgesetz), AIC-Reihenfolge, Chow-Test, Kaplan-Meier-Schätzer, Gini-Koeffizient, Post-Breakthrough-Dynamik und TAS-Gap-Berechnung.

Für die Ausgabeformatierung sind zwei Präzisionsklassen getrennt getestet: einheitliche Dezimalstellen in CSV-Ausgaben (`normalize_columns`) und gleichmäßige Rundung von Fließkommazahlen in JSON-Ausgaben (`normalize_floats`). Alle 164 Tests werden mit 0 Fehlern ausgeführt.

### F3c — Lebensdauer von Weltrekorden

Die Lebensdauer eines Weltrekords wird als die Anzahl Tage gemessen, die vergehen, bis er durch einen neuen Rekord abgelöst wird. Für Rekorde, die zum Analysezeitpunkt noch Bestand haben, liegt eine *rechtszensierte* Beobachtung vor: Die tatsächliche Lebensdauer ist unbekannt, aber mindestens so lang wie der bisher vergangene Zeitraum.

Ursprünglich war eine einfache Trendanalyse geplant. Da aktive Rekorde zum Analysezeitpunkt jedoch rechtszensierte Beobachtungen erzeugen, die eine einfache Trendanalyse nicht korrekt verarbeiten kann, kommt stattdessen der Kaplan-Meier-Schätzer zum Einsatz.

Der **Kaplan-Meier-Schätzer** [DLAE<sup>+</sup>21] berücksichtigt diese zensierten Beobachtungen korrekt und gibt für jeden Zeitpunkt  $t$  die Wahrscheinlichkeit an, dass ein Weltrekord bis dahin noch steht. Der Median dieser Überlebensfunktion gibt an, nach wie vielen Tagen die Hälfte aller Rekorde eines Genres bereits gebrochen wurde. Voraussetzung des Schätzers ist nicht-informative Zensierung: Das Herausfallen eines Rekords aus dem Beobachtungszeitraum darf nicht mit seiner Lebensdauer zusammenhängen. Da die zensierten Rekorde hier ausschließlich solche sind, die zum Auswertungstichtag noch aktiv waren (administrative Zensierung durch den Analysezeitpunkt), ist diese Voraussetzung erfüllt.

Zum Vergleich der Lebensdauerverteilungen zwischen Genres wird der **Kruskal-Wallis-Test** eingesetzt. Als Effektgröße wird  $\eta^2 = (H - k + 1)/(N - k)$  berechnet [Lak13]. Paarweise Unterschiede werden mit dem **Mann-Whitney-U-Test** [Kim16] geprüft. Der **Gini-Koeffizient** misst, wie gleichmäßig die Verbesserungsgrößen verteilt sind ( $G = 0$ : alle gleich,  $G = 1$ : eine einzelne Verbesserung dominiert alles).

## Kapitel 3

# Ergebnisse

### 3.1 F1 — Prozentuale Zeitreduktion

Tabelle 3.1 zeigt die prozentuale Zeitreduktion aller 17 Spiele, sortiert nach Gesamtreduktion absteigend.

Tabelle 3.1: Prozentuale Zeitreduktion und jährliche Verbesserungsrate je Spiel (any%-Kategorie)

| Spiel                   | Genre            | Reduktion (%) | Jährl. Rate (%/a) |
|-------------------------|------------------|---------------|-------------------|
| Minecraft: Java Edition | Sandbox          | 99,5          | 8,9               |
| The Talos Principle     | Puzzle           | 95,9          | 12,8              |
| Portal                  | Puzzle           | 91,1          | 6,7               |
| Hollow Knight           | Action-Adventure | 89,8          | 12,8              |
| Celeste                 | Platformer       | 80,2          | 9,8               |
| Half-Life 2             | FPS              | 75,4          | 6,2               |
| Zelda: Ocarina of Time  | Action-Adventure | 71,2          | 15,8              |
| Pac-Man                 | Arcade           | 69,0          | 11,2              |
| Doom 3                  | FPS              | 61,6          | 4,8               |
| Portal 2                | Puzzle           | 55,2          | 4,0               |
| Quake                   | FPS              | 47,5          | 1,8               |
| Super Metroid           | Action-Adventure | 41,5          | 3,1               |
| Final Fantasy VII       | RPG              | 34,3          | 2,9               |
| Super Mario 64          | Platformer       | 27,1          | 1,4               |
| Donkey Konga            | Arcade           | 14,9          | 2,0               |
| Pokémon Red/Blue        | RPG              | 14,0          | 1,0               |
| Super Mario Bros.       | Platformer       | 9,4           | 0,4               |

Auf Genre-Ebene zeigen sich deutliche Unterschiede in der mittleren Gesamtreduktion: *Sandbox* (99,5 %), *Puzzle* (80,7 %), *Action-Adventure* (67,5 %) und *FPS* (61,5 %) liegen deutlich über *Arcade* (41,9 %), *Platformer* (38,9 %) und *RPG* (24,2 %). Der Kruskal-Wallis-Test auf die *jährlichen Verbesserungsraten* ergibt jedoch keinen signifikanten Unterschied zwischen den

sieben Genres ( $H = 6,24$ ;  $p = 0,284$ ).

**Finding 1:** Die prozentuale Zeitreduktion variiert stark zwischen Spielen (**9,4 % bis 99,5 %**). Spiele mit kurzer Spielzeit oder vielen nutzbaren Programmfehlern (*Minecraft*, Puzzle-Spiele) erzielen die höchsten Reduktionen.

**Finding 2:** Ein Kruskal-Wallis-Test auf die jährlichen Verbesserungsraten zeigt keinen statistisch signifikanten Unterschied zwischen Genres ( **$H = 6,24$ ;  $p = 0,284$** ). Die Verbesserungsrate hängt demnach stärker vom einzelnen Spiel als vom Genre ab.

### 3.2 F2 — Sättigung der Verbesserungsrate

Tabelle 3.2 fasst die Modellvergleiche zusammen. Über alle 17 Spiele gewinnt das quadratische Polynom (poly2) am häufigsten nach AIC (6/17 Spiele), gefolgt von Gompertz (5/17), exponentiellem Zerfall (4/17) und logarithmischer Regression (2/17). Der mittlere  $R^2$ -Wert des jeweils besten Modells beträgt 0,93 (Bereich: 0,73–0,98).

Tabelle 3.2: AIC-Modellvergleich: Siege und mittleres  $R^2$  je Modelltyp (alle 17 Spiele)

| Modell                   | Siege (von 17) | $\bar{R}^2$ |
|--------------------------|----------------|-------------|
| Quadr. Polynom (poly2)   | 6              | 0,901       |
| Gompertz                 | 4              | 0,961       |
| Exponentieller Zerfall   | 4              | 0,950       |
| Logarithmisch            | 2              | 0,929       |
| Potenzgesetz (power_law) | 1              | 0,720       |

Der Chow-Test zeigt für *alle 17 Spiele* einen statistisch signifikanten Strukturbruch. Tabelle 3.3 listet Bruchpunkt und  $F$ -Statistik je Spiel; alle  $F$ -Werte liegen deutlich über dem kritischen Wert ( $p < 0,001$ ). Bei 8 von 17 Spielen liegt der Bruchpunkt innerhalb der ersten 10 Weltrekorde, also sehr früh in der Community-Entwicklung.

**Finding 3:** Für **alle 17 Spiele** gelingt eine Kurvenanpassung mit  **$R^2 > 0,70$**  (Median: 0,95). Kein einzelnes Modell dominiert universell; *poly2* (6/17) erzielen die meisten Siege nach AIC, gefolgt von *Gompertz* und exponentiellem Zerfall (je 4/17). Modelle mit explizitem Sättigungsverhalten (Gompertz, Exp. Zerfall) gewinnen gemeinsam für 8/17 Spiele.

Tabelle 3.3: Chow-Test: Bruchpunkt (WR-Nummer) und  $F$ -Statistik je Spiel (alle  $p < 0,001$ )

| Spiel                   | Genre            | Bruchpunkt | $F$     |
|-------------------------|------------------|------------|---------|
| Celeste                 | Platformer       | WR #6      | 105,5   |
| Donkey Konga            | Arcade           | WR #8      | 52,1    |
| Doom 3                  | FPS              | WR #24     | 881,3   |
| Final Fantasy VII       | RPG              | WR #28     | 56,5    |
| Half-Life 2             | FPS              | WR #50     | 66,4    |
| Hollow Knight           | Action-Adventure | WR #33     | 33,6    |
| Minecraft: Java Edition | Sandbox          | WR #7      | 99,3    |
| Pac-Man                 | Arcade           | WR #4      | 54,7    |
| Pokémon Red/Blue        | RPG              | WR #20     | 54,1    |
| Portal                  | Puzzle           | WR #4      | 20162,0 |
| Portal 2                | Puzzle           | WR #28     | 64,3    |
| Quake                   | FPS              | WR #5      | 90,9    |
| Super Mario Bros.       | Platformer       | WR #10     | 410,0   |
| Super Mario 64          | Platformer       | WR #16     | 118,9   |
| Super Metroid           | Action-Adventure | WR #53     | 20,4    |
| The Talos Principle     | Puzzle           | WR #23     | 161,8   |
| Zelda: Ocarina of Time  | Action-Adventure | WR #10     | 488,4   |

**Finding 4: Alle 17 Spiele** weisen einen statistisch signifikanten Strukturbruch auf (Chow-Test,  $p < 0,05$ ). Bei **8 von 17 Spielen** tritt der Bruchpunkt innerhalb der ersten 10 Weltrekorde auf; bei Spielen mit langer WR-Geschichte liegt er deutlich später (Median: WR #16). In beiden Fällen folgt auf den initialen Optimierungsschub (Routing, *Glitch*-Entdeckungen) eine flachere *Sättigungsphase*.

### 3.3 F3 — Externer Einfluss auf die Rekordentwicklung

#### F3a — Post-Breakthrough-Dynamik

Tabelle 3.4 zeigt das Flattening Ratio sowie Breakthrough-Kennzahlen für alle Spiele, bei denen Pre- und Post-Breakthrough-Segmente ermittelt werden konnten.

**Finding 5: 5 von 6** auswertbaren Spielen zeigen ein Plateau nach dem Breakthrough ( $\phi < 0,5$ ). Nur *Donkey Konga* zeigt eine Beschleunigung ( $\phi = 23,97$ ) — der Breakthrough (WR #9, Dezember 2024) liegt so kurz zurück, dass die Post-Phase nur wenige Folgeverbesserungen enthält. Die stärksten Plateaus weisen *Zelda: Ocarina of Time* und *The Talos Principle* auf (je  $\phi = 0,02$ ;  $\rho = -0,79$ ;  $p < 0,001$ ). Der Breakthrough-

Tabelle 3.4: Post-Breakthrough-Dynamik: Flattening Ratio  $\phi$  und Post-Trend  $\rho$  je Spiel (any%-Kategorie,  $n = 6$ )

| Spiel                  | Break (s) | % Ges. | $\phi$ | $\rho$   | Interpretation  |
|------------------------|-----------|--------|--------|----------|-----------------|
| Donkey Konga           | 291,0     | 42,4   | 23,97  | n. a.    | Beschleunigung  |
| Pokémon Red/Blue       | 138,0     | 13,6   | 0,44   | +0,31    | Plateau         |
| Portal 2               | 432,8     | 16,1   | 0,35   | -0,54*   | Plateau         |
| Quake                  | 183,0     | 29,4   | 0,04   | -0,49    | Starkes Plateau |
| Zelda: Ocarina of Time | 116,2     | 20,6   | 0,02   | -0,79*** | Starkes Plateau |
| The Talos Principle    | 864,0     | 19,0   | 0,02   | -0,79*** | Starkes Plateau |

% Ges. = Breakthrough-Anteil an der Gesamtreduktion. \*  $p < 0,05$ ; \*\*\*  $p < 0,001$ ;  
 n. a. = zu wenige Post-WRs für Spearman-Test. 11 von 17 Spielen hatten  
 unzureichende Segmentgröße für die Velocity-Berechnung.

Anteil an der Gesamtreduktion reicht von **13,6 %** (*Pokémon Red/Blue*)  
 bis **42,4 %** (*Donkey Konga*).

### F3b — Annäherung ans theoretische Minimum

Tabelle 3.5 zeigt den modellbasierten Asymptoten-Proxy für alle 17 Spiele.

Tabelle 3.5: Modellbasierter Asymptoten-Proxy: Theoretisches Minimum aus exp\_decay-Modell ( $R^2 \geq 0,70$ )

| Spiel                                                                                         | Modell-Floor (s) | Gap (s) | % Reduktion erreicht |
|-----------------------------------------------------------------------------------------------|------------------|---------|----------------------|
| Half-Life 2                                                                                   | 1874,7           | 315,6   | 95,5                 |
| Pokémon Red/Blue                                                                              | 6004,4           | 215,6   | 82,5                 |
| Weitere 15 Spiele: <i>none_detected</i> — kein konvergentes Sättigungsmodell ( $R^2 < 0,70$ ) |                  |         |                      |

**Finding 6:** Für **2 von 17 Spielen** konnte ein konvergentes Sättigungsmodell berechnet werden: *Half-Life 2* hat **95,5 %** der möglichen Reduktion bis zum Modell-Floor erreicht (Floor: 1874,7 s, aktueller WR: 2190,3 s), *Pokémon Red/Blue* **82,5 %** (Floor: 6004,4 s). Für die übrigen **15 Spiele** ist kein stabiler Grenzwert bestimmbar (*none\_detected*) — diese Communities befinden sich noch in einer aktiven Entdeckungsphase.

### F3c — Lebensdauer von Weltrekorden

Tabelle 3.6 zeigt den Kaplan-Meier-Median und die 1-Jahres-Überlebensrate je Genre. Von den 842 Weltrekord-Datenpunkten sind 17 zum Analysezeitpunkt noch aktiv (rechtszensiert).

Der Kruskal-Wallis-Test zeigt einen hochsignifikanten Unterschied in den Lebensdauerverteilungen zwischen Genres ( $H(6) = 43,82$ ;  $p < 0,001$ ;

Tabelle 3.6: Kaplan-Meier-Schätzungen der Weltrekord-Lebensdauer nach Genre

| Genre            | Median (d) | Überleben 1 Jahr | <i>n</i> | Gini  |
|------------------|------------|------------------|----------|-------|
| RPG              | 52         | 15,5 %           | 58       | 0,655 |
| FPS              | 14         | 10,6 %           | 146      | 0,753 |
| Action-Adventure | 14         | 6,4 %            | 140      | 0,716 |
| Platformer       | 17         | 6,0 %            | 209      | 0,878 |
| Arcade           | 7          | 18,8 %           | 32       | 0,838 |
| Puzzle           | 8          | 6,5 %            | 197      | 0,849 |
| Sandbox          | 7          | 5,0 %            | 60       | 0,918 |

$\eta^2 \approx 0,044$ , kleiner bis mittlerer Effekt). Paarweise Mann-Whitney-U-Tests belegen, dass sich RPG von allen anderen Genres außer Arcade signifikant unterscheidet ( $p < 0,05$ ). Die übrigen Genres unterscheiden sich untereinander weniger konsistent.

Der Gini-Koeffizient der Verbesserungsgrößen ist in allen Genres hoch ( $G = 0,655\text{--}0,918$ ): Ein kleiner Anteil der Weltrekorde macht den Großteil der erzielten Zeitersparnis aus.

Im Jahrzehntvergleich zeigen Rekorde aus den 2000er Jahren die höchste mittlere Lebensdauer (665,8 Tage), gefolgt von den 1990er Jahren (172,7 Tage). Rekorde der 2010er (82,4 Tage) und 2020er (95,2 Tage) sind deutlich kurzlebiger.

**Finding 7:** Die Lebensdauer von Weltrekorden unterscheidet sich signifikant zwischen Genres (Kruskal-Wallis:  $H(6) = 43,82$ ;  $p < 0,001$ ;  $\eta^2 = 0,044$ ). Das Genre erklärt etwa **4,4 %** der Varianz in der Lebensdauer — ein statistisch gesicherter, inhaltlich moderater Effekt.

**Finding 8:** *RPG*-Rekorde überleben mit einem Kaplan-Meier-Median von **52 Tagen** signifikant länger als Rekorde anderer Genres (Median: **7–17 Tage**). Die geringere Spielgeschwindigkeit und die größere Komplexität von *RPGs* erschweren schnelle Optimierungen.

**Finding 9:** Im Jahrzehntvergleich sinkt die mittlere Rekordlebensdauer von **665,8 Tagen** (2000er) auf **82,4 Tage** (2010er). Der Einbruch fällt zeitlich mit dem starken Wachstum der Speedrunning-Community ab **2010** zusammen, das den Wettbewerbsdruck erhöhte.

# Kapitel 4

## Diskussion

### 4.1 Interpretation der Ergebnisse

#### F1 — Zeitreduktion

Die starke Variation der Zeitreduktion (9,4 %–99,5 %) liegt nicht am Genre — der Kruskal-Wallis-Test zeigt keinen signifikanten Genreeffekt auf die jährlichen Verbesserungsraten. Entscheidender sind spielspezifische Faktoren: Spiele mit kurzer Grundlaufzeit und nutzbaren Programmfehlern (Minecraft < 2 Min., Portal < 10 Min.) lassen sich stärker optimieren als Spiele, bei denen physikalische oder spielbedingte Grenzen eine weitere Verkürzung verhindern (Super Mario Bros.: jedes Frame zählt, wenige Glitches verfügbar). Innerhalb des RPG-Genres ist die Spiellänge der begrenzende Faktor — Final Fantasy VII dauert im Normalspiel über 35 Stunden.

#### F2 — Sättigung

Der universelle Strukturbruch (alle 17 Spiele, Chow-Test signifikant) ist das stärkste Ergebnis von F2. Er deutet darauf hin, dass Speedrunning-Optimierung nicht linear verläuft: Eine frühe *Hochaktivitätsphase* (intensive Routing-Suche, Entdeckung spielverändernder Glitches) geht in eine flachere *Plateau-Phase* über, in der nur noch marginale Verbesserungen möglich sind. Die Tatsache, dass der Strukturbruch häufig schon bei den ersten 10 Weltrekorden auftritt, legt nahe, dass frühe Mitglieder der Community den größten Teil der erreichbaren Optimierung erzielen. Das hohe  $R^2$  aller Modelle ( $> 0,70$ ) bestätigt, dass der Kurvenverlauf statistisch gut beschreibbar ist, unabhängig vom gewählten Modelltyp.

### F3a — Post-Breakthrough-Dynamik

Der hier gewählte Ansatz unterscheidet sich vom Chow-Test-Bruchpunkt aus F2: Der Chow-Test findet den Punkt mit dem stärksten Steigungswechsel in der *kumulierten* Zeitreihe und liegt typischerweise bei den ersten 10 WRs, weil die Verbesserungsrate dort am steilsten abfällt. Der Breakthrough hingegen markiert ein einmaliges Extremereignis — oft eine Glitch-Entdeckung — das zeitlich mit dem Chow-Bruch zusammenfallen, aber auch früher oder später auftreten kann.

Ein  $\phi < 0,5$  zeigt, dass die Community nach einem Durchbruch die neue Technik verfeinert, statt grundlegend neue Möglichkeiten zu suchen. Ein  $\phi > 1,0$  zeigt dagegen, dass der Durchbruch neue Glitch-Ketten oder Routing-Möglichkeiten freigelegt hat, die weitere schnelle Verbesserungen ermöglichen.

Für *Portal 2*, *Quake* und *The Talos Principle* stimmt der Breakthrough-Zeitpunkt exakt mit dem Chow-Test-Strukturbruch aus F2 überein (jeweils WR #28, #5 und #23) — ein Hinweis, dass der größte Einzelschritt der entscheidende Wendepunkt in der kumulierten Kurve ist. Bei *Zelda: Ocarina of Time* liegt der maximale Einzelschritt (WR #4, Januar 2020) sechs WRs vor dem Chow-Bruch (WR #10), was darauf hindeutet, dass ein früher Glitch-Fund das Routing fundamental veränderte, bevor sich die Verbesserungsgeschwindigkeit statistisch stabilisiert hatte.

*Donkey Konga* ist der markanteste Ausreißer:  $\phi = 23,97$  signalisiert eine Beschleunigung, nicht ein Plateau. Der Breakthrough (WR #9, Dezember 2024) liegt so kurz zurück, dass im Post-Segment kaum Konsolidierungszeit bestand — die hohe Verbesserungsgeschwindigkeit danach spiegelt vor allem direkte Folgeverbesserungen wider. Alle übrigen auswertbaren Spiele ( $n = 5$ ) zeigen ein klares Plateau ( $\phi \leq 0,44$ ), wobei *Zelda: OoT* ( $\phi = 0,02$ ) und *The Talos Principle* ( $\phi = 0,02$ ) mit  $\rho = -0,79$  ( $p < 0,001$ ) die stärkste Abnahme der Post-Breakthrough-Verbesserungen aufweisen. Das Ergebnis zeigt: Durchbrüche setzen die Abflachungsrate nicht zurück, sondern leiten direkt eine Konsolidierungsphase ein.

### F3b — Annäherung ans theoretische Minimum

Der Asymptoten-Proxy schätzt das theoretische Minimum einer WR-Kurve über den Grenzwert des besten Sättigungsmodells. Der  $R^2 \geq 0,70$ -Schwellenwert schließt Spiele ohne stabile Sättigungskurve aus, damit keine unzuverlässigen Schätzungen einfließen. Dass 15 von 17 Spielen als „none\_detected“ klassifiziert werden, ist kein Mangel der Methode, sondern ein inhaltliches Ergebnis: Diese Communities — darunter jüngere Spiele wie *Celeste* oder *Hollow Knight* — befinden sich noch in einer aktiven Entdeckungsphase, in der sich kein stabiler Grenzwert abzeichnet.

Für die zwei auswertbaren Spiele zeigt der Proxy, dass *Half-Life 2* mit

einem aktuellen WR von 2190,3 s bereits 95,5 % der möglichen Reduktion bis zum Modell-Floor (1874,7 s) erreicht hat. *Pokémon Red/Blue* liegt bei 82,5 %. Beide Spiele sind damit weit in die Sättigungsphase eingetreten.

Ein direkter Vergleich mit realen TAS-Zeiten war nicht möglich: Verlässliche TAS-Daten sind weder über eine öffentliche API verfügbar, noch lassen sie sich ohne Frame-genaue Videoanalyse zuverlässig erheben — dabei ist zu berücksichtigen, dass TAS-Videos nicht immer vom tatsächlichen Spielstart beginnen, was die Zeitauswertung zusätzlich erschwert.

### F3c — Lebensdauer

Das Jahrzehntmuster — lange Lebensdauer in den 2000ern, drastischer Rückgang ab 2010 — passt zur historischen Entwicklung der Speedrunning-Community. Vor der Gründung von *speedrun.com* (2014) und der Popularisierung über Streaming-Plattformen gab es deutlich weniger aktive Speedrunner, sodass Weltrekorde länger unangefochten blieben. Der moderate Effekt ( $\eta^2 \approx 0,044$ ) zeigt, dass das Genre zwar eine messbare Rolle spielt, aber bei weitem nicht der einzige Einflussfaktor ist. Community-Größe, Spielalter und Popularität auf Streaming-Plattformen sind wahrscheinlich stärkere Einflussfaktoren, lagen im Datensatz aber nicht vor.

Der hohe Gini-Koeffizient in allen Genres ( $G = 0,65\text{--}0,92$ ) zeigt, dass Weltrekordverbesserungen sehr ungleich verteilt sind: Wenige Schlüsselerdeckungen (Glitches, neue Routen) machen den Großteil der Zeitersparnis aus, während die meisten späteren Rekorde nur winzige Sekundenbruchteile einsparen.

### Einordnung in bestehende Forschung

Erdil und Sevilla [ES23] zeigen anhand von 1.731 Weltrekorden aus 100 Spielen, dass WR-Verbesserungen Potenzgesetz-Mustern folgen und systematische Trendbrüche aufweisen. Diese Arbeit bestätigt den Strukturbruch-Befund (F2, Chow-Test für alle 17 Spiele signifikant) auf einem kleineren, aber detaillierter ausgewerteten Datensatz. Zusätzlich werden drei Fragen untersucht, die bei Erdil und Sevilla offen bleiben: Post-Breakthrough-Dynamik (F3a), Annäherung ans theoretische Minimum (F3b) und Genre-Vergleich der Lebensdauer (F3c). Ein direkter Ergebnisvergleich ist nicht möglich, da Spielsets, Zeiträume und Kategorien abweichen.

## 4.2 Limitationen

**Stichprobengröße:** Mit 17 Spielen ist der Datensatz klein. Verallgemeinerungen auf alle Genres sind daher nur eingeschränkt möglich.

**Kategorie any%:** Die Beschränkung auf any% schließt andere gängige Kategorien aus (z. B. 100%, No-Major-Glitches). Die Dynamiken können sich

je nach Kategorie erheblich unterscheiden.

**Plattformbias:** *speedrun.com* hat einen Schwerpunkt auf PC-Spielen und englischsprachige Communities. Konsolen-Speedrunning und nicht-englischsprachige Spiele sind unterrepräsentiert.

**Fehlende Kontrollvariablen:** Community-Größe, Spieleranzahl und Medienaufmerksamkeit lagen nicht vor, obwohl sie Lebensdauer und Verbesserungsrate stark beeinflussen dürften.

**Kein TAS-Vergleich:** Ein direkter Vergleich mit TAS-Zeiten war nicht realisierbar. Keine öffentliche API liefert verlässliche TAS-Daten; die vorhandenen TAS-Videos erfordern Frame-genaue Auswertung des Startzeitpunkts, was im gegebenen Zeitrahmen nicht leistbar war. Der Asymptoten-Proxy ist daher nur ein Näherungswert für das theoretische Minimum.

**Kausalität:** Alle Ergebnisse zeigen Zusammenhänge, keine Ursachen. Aussagen wie „Glitches *verursachen* Strukturbrüche" lassen sich aus diesen Daten nicht belegen.

# Kapitel 5

## Fazit

Diese Ausarbeitung hat drei Forschungsfragen zur Dynamik von Speedrunning-Weltrekorden auf *speedrun.com* untersucht. Die wichtigsten Ergebnisse im Überblick:

Die **Zeitreduktion** variiert zwischen Spielen erheblich (**9,4 %–99,5 %**) und wird stärker von spielspezifischen Faktoren wie Spiellänge und verfügbaren Glitches bestimmt als vom Genre (kein signifikanter Genreunterschied, **p = 0,284**).

Der **Sättigungspunkt** ist in allen 17 Spielen statistisch nachweisbar: Der Chow-Test zeigt universelle Strukturbrüche, die typischerweise in der frühen Rekordphase auftreten. Die Verbesserungskurve lässt sich mit hoher Güte modellieren (**R<sup>2</sup> > 0,70**), wobei kein einzelnes Modell für alle Spiele optimal ist.

Der **externe Einfluss** auf die Rekordentwicklung wurde in drei Teilfragen aufgeteilt. **F3c (Lebensdauer)** ist vollständig beantwortet: Die Lebensdauer unterscheidet sich signifikant zwischen Genres (**H(6) = 43,82; p < 0,001**). **RPG**-Rekorde halten mit einem Median von **52 Tagen** deutlich länger als Rekorde anderer Genres (**7–17 Tage**); der Rückgang ab den 2010er Jahren korreliert mit dem Wachstum der Speedrunning-Community.

**F3a (Post-Breakthrough-Dynamik)** misst erstmals, ob und wie stark ein konkreter Durchbruch die Verbesserungsrate einer Community verändert. Das Flattening Ratio  $\phi$  macht diesen Effekt messbar — auf Basis öffentlich zugänglicher WR-Daten und damit reproduzierbar.

Für 6 von 17 Spielen konnte  $\phi$  berechnet werden. **5 dieser 6 Spiele** zeigen ein klares Plateau ( $\phi < 0,5$ ), insbesondere *Zelda: Ocarina of Time* und *The Talos Principle* ( $\phi = 0,02$  jeweils). Nur *Donkey Konga* zeigt eine Beschleunigung ( $\phi = 23,97$ ) — ein Sonderfall, weil der Breakthrough (Dezember 2024) erst kurz zurückliegt. Der dominierende Befund ist das Plateau: Durchbrüche setzen die Abflachungsrate nicht zurück, sondern leiten unmittelbar eine Konsolidierungsphase ein.

**F3b (Annäherung ans theoretische Minimum)** schätzt über den

mathematischen Grenzwert der Sättigungskurve, wie nah menschliche Weltrekorde dem theoretisch möglichen Minimum kommen. Ein direkter Vergleich mit TAS-Zeiten war nicht realisierbar, da verlässliche TAS-Daten weder per API verfügbar sind noch ohne Frame-genaue Videoanalyse erhoben werden können.

Für **2 von 17 Spielen** konnte ein konvergentes Sättigungsmodell berechnet werden: *Half-Life 2* hat 95,5 % der möglichen Reduktion bis zum Modell-Floor erreicht, *Pokémon Red/Blue* 82,5 %. Für die übrigen **15 Spiele** ist kein stabiler Grenzwert bestimmbar — diese Communities befinden sich noch in einer aktiven Entdeckungsphase.

## Ausblick

Weiterführende Analysen könnten die Stichprobe auf 100 oder mehr Spiele erweitern und zusätzliche Kategorien (100%, Glitchless) einbeziehen. Eine Verknüpfung mit Community-Metriken (Anzahl aktiver Speedrunner, Twitch-Zuschauerzahlen) würde ermöglichen, die beobachteten Muster kausal zu erklären. Maschinelle Lernverfahren könnten eingesetzt werden, um die verbleibende Optimierungsspanne für aktive Rekorde vorherzusagen.

# Literaturverzeichnis

- [DLAE<sup>+</sup>21] G. D’Arrigo, D. Leonardis, S. Abd ElHafeez, M. Fusaro, G. Tripepi, and S. Roumeliotis. Methods to analyse time-to-event data: The Kaplan-Meier Survival Curve. *Oxidative Medicine and Cellular Longevity*, 2021, 2021. doi:10.1155/2021/2490601. Open Access, PMC8478547.
- [DTY18] J. Ding, V. Tarokh, and Y. Yang. Model selection techniques — An overview. *IEEE Signal Processing Magazine*, 35(6):16–34, 2018, 1810.09583. doi:10.1109/MSP.2018.2867638. Open Access via arXiv:1810.09583.
- [ES23] E. Erdil and J. Sevilla. Power law trends in speedrunning and machine learning, 2304.10004. URL <https://arxiv.org/abs/2304.10004>. Abgerufen am 15. Mai 2026.
- [Kim16] H. K. Kim. Nonparametric statistical tests for the continuous data: the basic concept and the practical use. *Korean Journal of Anesthesiology*, 69(1):8–14, 2016. doi:10.4097/kjae.2016.69.1.8. Open Access, PMC4754273.
- [Lak13] D. Lakens. Calculating and reporting effect sizes to facilitate cumulative science: a practical primer for t-tests and ANOVAs. *Frontiers in Psychology*, 4:863, 2013. doi:10.3389/fpsyg.2013.00863. Open Access, PMC3840331.
- [spe24a] speedrun.com. speedrun.com API v1 Documentation. <https://github.com/speedruncomorg/api>, 2024. Abgerufen am 15. Mai 2026; TAS-Runs werden auf regulären Leaderboards nicht gelistet und sind über die API nicht abrufbar.
- [spe24b] speedrun.com. speedrun.com site rules. <https://www.speedrun.com/support/learn/site-rules>, 2024. Abgerufen am 17. Mai 2026; bestätigt TAS-Verbot auf regulären Leaderboards.

- [ZLHK02] A. Zeileis, F. Leisch, K. Hornik, and C. Kleiber. strucchange: An R package for testing for structural change in linear regression models. *Journal of Statistical Software*, 7(2):1–38, 2002. doi:10.18637/jss.v007.i02. Open Access.